

BÁO CÁO BÀI 1 - HIỂU DỮ LIỆU, CHỌN DỮ LIỆU VÀ TIỀN XỬ LÝ

1. Mục tiêu

Khảo sát ba bộ dữ liệu đã chọn, đánh giá khả năng áp dụng phân lớp, luật kết hợp và gom cụm; đồng thời thực hiện tiền xử lý để tạo dữ liệu đầu vào cho các bài kỹ thuật tiếp theo.

2. Ba bộ dữ liệu sử dụng

Bộ dữ liệu	Quy mô đã dùng	Vai trò chính
Diabetes 130-US Hospitals	101.766 bản ghi; dữ liệu sau xử lý 46 cột	Phân lớp readmitted; luật kết hợp
Human Activity Recognition (HAR)	10.299 bản ghi; 561 đặc trưng + 2 cột nhãn	Gom cụm; có thể hỗ trợ phân lớp
Retail	Dữ liệu giao dịch bán lẻ đã tiền xử lý	Khảo sát cấu trúc giao dịch và khả năng khai phá

3. Ma trận dữ liệu × kỹ thuật

Bộ dữ liệu	Phân lớp	Luật kết hợp	Gom cụm
Diabetes	Có	Có	Có thể
HAR	Có	Không ưu tiên	Có
Retail	Có thể	Có	Có

4. Điều tra và tiền xử lý

4.1 Diabetes

Dữ liệu chứa cả thuộc tính số và hạng mục. Các giá trị hạng mục thiếu/không xác định được thống nhất cách biểu diễn; các thuộc tính định danh không mang ý nghĩa dự đoán được loại khỏi tập đặc trưng khi cần. Với phân lớp, thuộc tính số được chuẩn hóa và thuộc tính hạng mục được One-Hot Encoding. Với luật kết hợp, các thuộc tính hạng mục được chuyển thành dạng giao dịch nhị phân.

4.2 HAR

Bộ HAR có 561 đặc trưng số nên phù hợp với các thuật toán dựa trên khoảng cách. Hai cột activity_id và activity_name được giữ làm nhãn tham chiếu nhưng không đưa vào quá trình gom cụm. Toàn bộ đặc trưng đầu vào được chuẩn hóa bằng StandardScaler.

4.3 Retail

Dữ liệu được khảo sát theo hướng giao dịch. Trong quá trình thử nghiệm, cấu trúc dữ liệu đã xử lý không tạo được giỏ hàng đủ phong phú cho bài luật kết hợp vì mỗi khách hàng/giao dịch quan sát được quá ít nhóm sản phẩm đồng xuất hiện. Vì vậy Bài 3 được thực hiện trên Diabetes.

5. Kết luận

Sau tiền xử lý, ba bộ dữ liệu phủ được ba kỹ thuật yêu cầu. Diabetes được chọn cho phân lớp và luật kết hợp; HAR được chọn cho gom cụm. Các file processed được sử dụng thống nhất ở các bài tiếp theo để bảo đảm khả năng chạy lại.