

BÁO CÁO BÀI 2 - PHÂN LỚP (CLASSIFICATION)

1. Xác định bài toán

Sử dụng Diabetes 130-US Hospitals để dự đoán biến readmitted gồm ba lớp: NO, >30 và <30. Dữ liệu sau tiền xử lý có 101.766 bản ghi và 46 cột. Phân bố lớp là NO 53,91%, >30 34,93% và <30 11,16%, cho thấy dữ liệu mất cân bằng.

2. Chuẩn bị dữ liệu

Biến readmitted được tách làm y. patient_nbr bị loại khỏi X vì là mã định danh. X còn 44 thuộc tính gồm 11 thuộc tính số và 33 thuộc tính phân loại. Dữ liệu được chia 80% train (81.412 bản ghi) và 20% test (20.354 bản ghi), có stratify=y.

Thuộc tính số được StandardScaler; thuộc tính phân loại dùng OneHotEncoder(handle_unknown='ignore'). Các bước được đặt trong Pipeline để hạn chế rò rỉ dữ liệu.

3. Thuật toán và tham số

Thuật toán	Cơ chế/giả định	Tham số chính
Logistic Regression	Mô hình xác suất tuyến tính, baseline đa lớp.	max_iter=1000
Decision Tree	Chia không gian đặc trưng theo ngưỡng; mô hình hóa phi tuyến.	max_depth=10; class_weight=balanced
Random Forest	Kết hợp nhiều cây để giảm phương sai.	n_estimators=100; max_depth=15; class_weight=balanced

4. Kết quả đánh giá

Mô hình	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0,5774	0,5369	0,5774	0,5270	0,6490

Decision Tree	0,4913	0,5321	0,4913	0,5060	0,6396
Random Forest	0,4892	0,5428	0,4892	0,5055	0,6553

Logistic Regression có Accuracy và F1 weighted cao nhất. Random Forest có ROC-AUC macro cao nhất (0,6553). Confusion matrix cho thấy Logistic Regression thiên về lớp NO và nhận diện lớp <30 kém hơn.

5. Xử lý mất cân bằng

Khi thử Logistic Regression với `class_weight='balanced'`, Accuracy giảm từ 0,5774 xuống 0,4787 và F1 weighted giảm từ 0,5270 xuống 0,4993, nhưng recall lớp <30 tăng từ 0,0233 lên 0,4058. Đây là sự đánh đổi giữa hiệu quả tổng thể và khả năng nhận diện lớp thiểu số.

6. Kết luận

Do dữ liệu mất cân bằng, không nên chỉ sử dụng Accuracy. Cần xem đồng thời Precision, Recall, F1, confusion matrix và ROC-AUC. Logistic Regression cho kết quả tổng thể tốt hơn theo Accuracy/F1 trong thử nghiệm hiện tại.