

BÁO CÁO BÀI 4 - GOM CỤM (CLUSTERING)

1. Dữ liệu và chuẩn bị

Bài gom cụm sử dụng UCI Human Activity Recognition (HAR) gồm 10.299 bản ghi. Tập đầu vào có 561 đặc trưng số. activity_id và activity_name được loại khỏi X; activity_name chỉ dùng sau khi gom cụm để profiling.

Toàn bộ đặc trưng được chuẩn hóa bằng StandardScaler vì K-Means và Ward dựa trên khoảng cách. Sau chuẩn hóa, trung bình xấp xỉ 0, độ lệch chuẩn xấp xỉ 1 và không có NaN/Inf.

2. Thuật toán và giả định

Thuật toán	Cơ chế/giả định
K-Means	Gán điểm vào tâm gần nhất và cập nhật tâm; tối thiểu hóa tổng bình phương khoảng cách trong cụm.
Agglomerative Clustering (Ward)	Gộp dần các cụm; Ward chọn phép gộp làm tăng phương sai trong cụm ít nhất.

3. Chọn số cụm

K-Means được thử với K từ 2 đến 8. Silhouette lần lượt: K2=0,3955; K3=0,3130; K4=0,1510; K5=0,1317; K6=0,1096; K7=0,0798; K8=0,0743. K=2 có Silhouette cao nhất nên được chọn. Elbow/inertia cũng được trực quan hóa để hỗ trợ quyết định.

4. Kết quả so sánh

Thuật toán	Số cụm	Silhouette	Davies-Bouldin	Quy mô cụm
K-Means	2	0,3955	1,0707	5.620 / 4.679
Agglomerative (Ward)	2	0,3953	1,0717	5.627 / 4.672

Hai thuật toán cho kết quả gần tương đương. K-Means có Silhouette cao hơn rất nhẹ và Davies-Bouldin thấp hơn rất nhẹ; chênh lệch không lớn.

5. PCA và profiling

PCA được dùng để trực quan hóa, giảm 561 chiều xuống 2 chiều; hai thành phần đầu giải thích khoảng 56,98% phương sai. PCA không được dùng để huấn luyện lại mô hình.

Cụm 0 có 5.620 bản ghi và khoảng 99,86% là các hoạt động tĩnh gồm LAYING, SITTING và STANDING. Cụm 1 có 4.679 bản ghi và gần như toàn bộ là WALKING, WALKING_UPSTAIRS hoặc WALKING_DOWNSTAIRS. Nhân hoạt động chỉ được dùng hậu nghiệm để profiling.

6. Kết luận

Trong phạm vi $K=2..8$, $K=2$ là lựa chọn tốt nhất theo Silhouette. Hai thuật toán phát hiện cấu trúc cụm gần giống nhau; profiling cho thấy hai cụm tương ứng rõ với nhóm hoạt động tĩnh và vận động.